

PROCESSO SELETIVO

AI Engineer

Teste Técnico

Guia de estudo e gabarito comentado para nível sênior. Cada pergunta traz a resposta direta e uma explicação didática ilustrada, pensada para quem quer realmente entender — não apenas decorar.

10

GRANDES TEMAS

50

PERGUNTAS

1-3 min

POR RESPOSTA

SUMÁRIO

Conteúdo do teste

Dez blocos que percorrem toda a stack de um AI Engineer — dos fundamentos de machine learning à operação de LLMs em produção com segurança. Cada tema abre com sua própria página de índice.

01	Machine Learning	3
	5 perguntas	
02	Fundamentos de LLM	9
	5 perguntas	
03	Engenharia de Dados para IA	15
	5 perguntas	
04	LLMs, Fine-tuning e Adaptação de Modelos	21
	5 perguntas	
05	Engenharia de Prompt e Contexto	27
	5 perguntas	
06	RAG e Sistemas de Recuperação	33
	5 perguntas	
07	Agentes, Ferramentas e Integração	39
	5 perguntas	
08	Avaliação, Testes e Observabilidade	45
	5 perguntas	
09	Arquitetura e Engenharia em Produção	51
	5 perguntas	
10	Segurança, Privacidade e IA Responsável	57
	5 perguntas	

TEMA 1

Machine Learning

A base estatística que sustenta qualquer sistema de IA: como um modelo aprende, quando ele falha e como medir se está funcionando.

PERGUNTAS DESTE TEMA

1.1	Qual a diferença entre overfitting e underfitting, e como detectar cada um?	4
1.2	O que é o trade-off entre viés e variância (bias-variance)?	5
1.3	Por que usamos funções de ativação não-lineares em redes neurais?	6
1.4	O que é o problema do vanishing gradient e como mitigá-lo?	7
1.5	Acurácia é uma boa métrica para dados desbalanceados? O que usar no lugar?	8

Qual a diferença entre overfitting e underfitting, e como detectar cada um?

RESPOSTA RÁPIDA

Overfitting: o modelo decora o treino (erro baixo no treino, alto na validação). Underfitting: o modelo é simples demais e vai mal nos dois. Detecta-se comparando o erro de treino com o de validação.


Entendendo a fundo

Imagine um estudante que decora as respostas de uma prova antiga em vez de entender a matéria. Ele gabarita aquela prova, mas erra tudo numa prova nova. Isso é overfitting: o modelo ajustou-se tão bem aos dados de treino que capturou até o ruído deles, e por isso não generaliza para dados novos.

O oposto é o underfitting: o estudante que estudou de menos e vai mal em qualquer prova. O modelo é simples demais para capturar o padrão real dos dados.

Como você não vê o “futuro”, separa parte dos dados para validação e compara os dois erros. Erro de treino baixo e de validação alto (um “gap” grande) indica overfitting. Ambos altos indica underfitting. O alvo é o ponto no meio, em que o modelo aprende o padrão sem decorar o ruído.

Underfitting



Ajuste ideal



Overfitting



Mesmos pontos, três ajustes: simples demais, equilibrado e complexo demais.

O que é o trade-off entre viés e variância (bias-variance)?

RESPOSTA RÁPIDA


O erro de generalização se decompõe em viés (modelo rígido demais, subajusta) e variância (modelo sensível demais ao treino, superajusta). Aumentar a complexidade troca um pelo outro; busca-se o equilíbrio.

Entendendo a fundo

Todo erro de um modelo pode ser dividido em duas fontes. O viés é o erro por o modelo ser rígido demais — ele assume uma forma simples (por exemplo, uma reta) e erra sistematicamente porque a realidade é mais complexa. A variância é o erro por o modelo ser sensível demais: pequenas mudanças nos dados de treino mudam muito o resultado, sinal de que ele está capturando ruído.

O ponto central é que os dois puxam em direções opostas. Modelos simples têm viés alto e variância baixa; modelos complexos, o contrário. Reduzir um tende a aumentar o outro.

Na prática, viés alto é underfitting e variância alta é overfitting. O objetivo do ajuste (regularização, escolha de complexidade, mais dados) é encontrar o vale onde a soma dos dois — o erro total — é mínima.



O erro total é a soma de viés e variância; o mínimo fica no equilíbrio.

Por que usamos funções de ativação não-lineares em redes neurais?

RESPOSTA RÁPIDA

Sem não-linearidade, empilhar várias camadas lineares equivale a uma única transformação linear. A ativação não-linear é o que dá poder expressivo à profundidade da rede.

Entendendo a fundo

Uma camada de rede neural, no fundo, faz uma operação linear (multiplica por pesos e soma). O detalhe matemático crucial é que a composição de operações lineares continua sendo linear: empilhar dez camadas lineares dá exatamente o mesmo que uma só. Ou seja, sem mais nada, uma rede “profunda” teria o poder de um modelo raso — só conseguiria separar dados por uma reta (ou plano).

A função de ativação não-linear (ReLU, sigmoide, etc.) é inserida entre as camadas para quebrar essa linearidade. Cada camada passa a poder “dobrar” o espaço, e a composição de muitas dobras permite representar fronteiras curvas e relações arbitrariamente complexas.

É por isso que a não-linearidade não é um detalhe: é ela que transforma profundidade em capacidade de aprender.

Só camadas lineares

- N camadas lineares = 1 linear
- Só separa por uma reta
- Não aprende relações complexas

Com ativação não-linear

- Cada camada dobra o espaço
- Fronteiras curvas
- Aprende padrões complexos

Sem ativação, a profundidade não agrega poder; com ela, a rede aprende curvas.

O que é o problema do vanishing gradient e como mitigá-lo?

RESPOSTA RÁPIDA

Em redes profundas, os gradientes encolhem ao retropropagar e as camadas iniciais quase não aprendem. Mitiga-se com ReLU, conexões residuais, normalização (batch/layer norm) e boa inicialização.

Entendendo a fundo

Redes aprendem por retropropagação: o erro na saída é propagado de volta, camada por camada, ajustando os pesos. Esse ajuste depende do gradiente. O problema é que, com certas ativações (como a sigmoide) e muitas camadas, o gradiente é multiplicado por números pequenos repetidas vezes e encolhe exponencialmente até quase zero ao chegar nas primeiras camadas.

Resultado: as camadas iniciais — que aprendem as características mais básicas — praticamente param de se ajustar, e o treino trava.

As arquiteturas modernas resolvem isso com: ativações como a ReLU (que não achata o gradiente na região positiva); conexões residuais (skip connections), que criam um “atalho” para o gradiente fluir; normalização (batch ou layer norm); e uma inicialização de pesos adequada. Foi esse conjunto que tornou viável treinar redes muito profundas.



gradiente encolhe ao voltar -> camadas iniciais quase não aprendem

Ao retropropagar, o gradiente encolhe; as camadas iniciais mal se atualizam.

Acurácia é uma boa métrica para dados desbalanceados? O que usar no lugar?

RESPOSTA RÁPIDA

Não. Com classes desbalanceadas, prever sempre a classe majoritária dá acurácia alta e é inútil. Melhor usar precisão, recall, F1 ou AUC, conforme o custo de falsos positivos vs. falsos negativos.



Entendendo a fundo

Acurácia é a fração de acertos sobre o total. O problema aparece quando uma classe é rara. Se apenas 1% das transações são fraude, um modelo que simplesmente diz “nunca é fraude” acerta 99% das vezes — acurácia altíssima, e ao mesmo tempo completamente inútil, pois não pega nenhuma fraude.

Por isso, em dados desbalanceados, olhamos para métricas que separam os tipos de erro. Precisão responde “dentre os que marquei como fraude, quantos eram mesmo?”. Recall responde “dentre as fraudes reais, quantas eu peguei?”. O F1 combina as duas.

A escolha depende do custo do erro: se deixar passar uma fraude é caro, prioriza-se recall; se incomodar clientes com falsos alarmes é o problema, prioriza-se precisão. AUC-ROC e AUC-PR resumem o desempenho ao longo de vários limiares.

Dataset: 99% classe A / 1% classe B (fraude)



Prever sempre a classe majoritária: 99% de acurácia, 0% de recall na classe que importa.

Fundamentos de LLM

Como um modelo de linguagem realmente funciona por dentro: da arquitetura Transformer à forma como o texto entra, é processado e é gerado.

PERGUNTAS DESTE TEMA

2.1	O que é o mecanismo de self-attention e por que foi importante para os Transformers?	10
2.2	O que é tokenização e por que ela importa na prática?	11
2.3	O que significa dizer que um LLM é autorregressivo (previsão do próximo token)?	12
2.4	Qual a diferença entre embeddings estáticos e contextuais?	13
2.5	Para que serve o positional encoding em um Transformer?	14

O que é o mecanismo de self-attention e por que foi importante para os Transformers?

RESPOSTA RÁPIDA

Permite que cada token pondere a relevância de todos os outros da sequência, capturando dependências de longo alcance. Foi decisivo por paralelizar o processamento (ao contrário das RNNs) e captar contexto global.


Entendendo a fundo

Para entender uma palavra, muitas vezes é preciso olhar outras, às vezes distantes. Em “O gato que dormia caiu”, para saber quem caiu, o modelo precisa ligar “caiu” a “gato”. A self-attention faz exatamente isso: para cada token, ela calcula um peso de relevância em relação a todos os outros tokens e monta uma representação que mistura os mais importantes.

Antes dos Transformers, isso era feito por redes recorrentes (RNNs), que processavam palavra por palavra em sequência — lentas e com dificuldade de “lembrar” de conexões distantes.

A atenção trouxe duas vantagens que mudaram o campo: ela captura relações de longo alcance diretamente, e é paralelizável (todos os tokens são processados de uma vez, não em sequência). Essa paralelização é o que permitiu treinar modelos gigantescos de forma eficiente.

"caiu" pondera todos os tokens: liga forte a "gato" (o sujeito)



Cada token pesa todos os outros; aqui "caiu" liga-se fortemente ao sujeito "gato".

O que é tokenização e por que ela importa na prática?

RESPOSTA RÁPIDA

É a quebra do texto em unidades (tokens, pedaços de palavras), cada uma virando um id numérico. Importa porque custo e limite de contexto são medidos em tokens, e a tokenização afeta idiomas e formatos de forma desigual.

Entendendo a fundo

O modelo não enxerga letras nem palavras: ele trabalha com números. A tokenização é o passo que converte o texto em uma sequência de “tokens” — pedaços que costumam ser sub-partes de palavras — e depois em ids numéricos. “Tokenização”, por exemplo, pode virar três tokens.

Isso tem consequências práticas concretas. Primeiro, tudo é medido e cobrado em tokens, não em caracteres ou palavras: o limite de contexto e o preço da API dependem da contagem de tokens. Segundo, a eficiência varia por idioma e formato — português e código costumam gastar mais tokens que inglês para o mesmo conteúdo.

Também explica curiosidades, como o modelo errar ao contar quantas letras uma palavra tem: ele nunca viu as letras isoladas, apenas os tokens.

"tokenizacao"

token

id 4102

iza

id 9917

cao

id 388

1 palavra = 3 tokens. Custo, limite de contexto e cobrança são medidos em tokens.

Uma palavra pode virar vários tokens; cada token é um id numérico.

O que significa dizer que um LLM é autorregressivo (previsão do próximo token)?

RESPOSTA RÁPIDA


O modelo gera texto um token por vez, sempre prevendo o próximo condicionado a todos os anteriores; cada token gerado realimenta a entrada. Por isso a geração é sequencial e impacta a latência.

Entendendo a fundo

No fundo, um LLM faz uma coisa só, repetidamente: dado tudo o que veio antes, ele prevê qual é o próximo token mais provável. “Autorregressivo” é o nome desse padrão — a saída é gerada em função da própria saída anterior.

O processo é um laço: o modelo prevê um token, esse token é anexado ao texto, e o conjunto todo volta como entrada para prever o token seguinte. Assim, palavra a palavra, a resposta vai sendo construída.

Duas implicações importam ao engenheiro. A geração é intrinsecamente sequencial (não dá para gerar o quinto token sem ter o quarto), o que afeta diretamente a latência e explica por que respostas longas demoram mais. E é por isso que streaming existe: como os tokens saem um a um, dá para exibi-los conforme são gerados.



cada token previsto realimenta a entrada do proximo passo

Cada token previsto é anexado e realimenta a previsão do próximo.

Qual a diferença entre embeddings estáticos e contextuais?

RESPOSTA RÁPIDA

Estáticos (Word2Vec): cada palavra tem um vetor fixo, independente do contexto.

Contextuais (BERT, camadas de um LLM): o vetor muda conforme a frase, distinguindo sentidos diferentes da mesma palavra.

Entendendo a fundo

Embedding é a representação de um pedaço de texto como um vetor de números, onde a proximidade no espaço reflete proximidade de significado. A grande divisão é se esse vetor depende ou não do contexto.

Nos embeddings estáticos, como o Word2Vec, cada palavra tem um único vetor, decidido de uma vez. “Banco” recebe sempre o mesmo vetor, seja o de sentar, seja o financeiro — o modelo não distingue os sentidos.

Nos embeddings contextuais, produzidos por modelos como BERT ou pelas camadas internas de um LLM, o vetor da palavra é calculado levando em conta a frase inteira. Assim, “banco” em “sentei no banco” e em “fui ao banco” ganha representações diferentes. É essa sensibilidade ao contexto que dá aos modelos modernos boa parte de sua capacidade de entender linguagem.

Estatico (Word2Vec): "banco" = 1 vetor fixo

Contextual (LLM): o vetor muda com a frase

"sentei no banco"

região dos moveis/assentos

"fui ao banco"

região de finanças

banco (movel)

banco (finanças)

mesma palavra, posicoes diferentes no espaco semantico

A mesma palavra ocupa posições distintas no espaço semântico conforme a frase.

Para que serve o positional encoding em um Transformer?

RESPOSTA RÁPIDA

A self-attention, sozinha, é invariante à ordem (trata a sequência como um conjunto). O positional encoding injeta informação de posição nos embeddings, para o modelo distinguir a ordem das palavras.

Entendendo a fundo

Há uma propriedade curiosa da atenção: por si só, ela não tem noção de ordem. Ela olha todos os tokens “ao mesmo tempo” e trata a entrada como um conjunto, não como uma sequência. Isso é um problema, porque a ordem muda o sentido: “o homem mordeu o cão” e “o cão mordeu o homem” têm exatamente os mesmos tokens.

O positional encoding resolve isso adicionando a cada token uma informação de posição — um “carimbo” de onde ele está na sequência. Assim o modelo passa a distinguir a primeira palavra da terceira.


As primeiras versões usavam funções senoidais fixas; abordagens modernas costumam usar posições aprendidas ou relativas (como o RoPE). O conceito, porém, é o mesmo: sem esse carimbo de posição, o Transformer seria surdo à ordem.

Atencao sozinha = conjunto sem ordem



? ordem ambigua

+ Positional encoding = ordem definida



ordem preservada

Sem posição, a ordem é ambígua; o encoding devolve a noção de sequência.

Engenharia de Dados para IA

O modelo é tão bom quanto os dados que o alimentam. Aqui mora boa parte da diferença entre um sistema que funciona na demo e um que funciona em produção.

PERGUNTAS DESTE TEMA

3.1	O que é data leakage (vazamento de dados) e dê um exemplo.	16
3.2	Por que a qualidade dos dados costuma importar mais que a quantidade em fine-tuning?	17
3.3	Quais os riscos de treinar ou avaliar com dados sintéticos gerados por LLM?	18
3.4	Num sistema RAG, como manter o índice de embeddings atualizado quando os documentos mudam?	19
3.5	Por que versionar dados (datasets, eval sets), e não só código e modelos?	20

O que é data leakage (vazamento de dados) e dê um exemplo.

RESPOSTA RÁPIDA


É quando informação que não estaria disponível no momento da predição vaza para o treino, inflando as métricas offline e causando colapso em produção. Em LLMs, o análogo é a contaminação de benchmark.

Entendendo a fundo

Data leakage é um dos erros mais traiçoeiros porque não dá cara feia: pelo contrário, ele faz as métricas ficarem lindas. Acontece quando o modelo, durante o treino, tem acesso a alguma pista que na vida real só existiria depois — ou seja, ele “cola”.

Exemplos clássicos: normalizar os dados usando estatísticas do conjunto inteiro antes de separar treino e teste (o treino “vê” o teste); incluir uma variável que é consequência do que se quer prever; ou, em séries temporais, usar dados do futuro para prever o passado.

O sintoma é sempre o mesmo: desempenho excelente na avaliação, desempenho fraco em produção. Em LLMs, a versão desse problema é a contaminação de benchmark — quando itens do teste já apareceram nos dados de treino, e o modelo parece muito melhor do que é.



Por que a qualidade dos dados costuma importar mais que a quantidade em fine-tuning?

RESPOSTA RÁPIDA

O LLM já traz capacidade geral do pré-treino; o fine-tuning só ajusta comportamento. Poucos exemplos limpos e consistentes superam muitos ruidosos, que ensinam o modelo a errar. Curadoria tem ROI alto.

Entendendo a fundo

É tentador achar que “mais dados = melhor”, mas no fine-tuning essa intuição engana. O modelo já sabe linguagem e conhecimento geral do pré-treino; o fine-tuning não está ensinando o mundo do zero, apenas ajustando comportamento — estilo, formato, como responder a um tipo de tarefa.

Para isso, consistência vale mais que volume. Se o dataset tem rótulos contraditórios, exemplos duplicados ou respostas de baixa qualidade, você está literalmente ensinando o modelo a ser inconsistente e a errar. Poucos milhares de exemplos bem curados costumam bater dezenas de milhares mal rotulados.

Por isso, tempo gasto em curadoria — limpar, deduplicar, padronizar rótulo e formato, revisar casos difíceis — tem retorno altíssimo, muitas vezes maior do que coletar mais dados.

Poucos, mas limpos

- Consistentes e revisados
- Representativos da tarefa
- Modelo aprende o certo

Muitos, mas ruidosos

- Rótulos contraditórios
- Duplicatas e lixo
- Ensinam o modelo a errar

Poucos exemplos consistentes ensinam melhor do que muitos exemplos ruidosos.

Quais os riscos de treinar ou avaliar com dados sintéticos gerados por LLM?

RESPOSTA RÁPIDA


Propagar vieses e erros do gerador; colapso de distribuição por baixa diversidade; contaminação, se os sintéticos vazam para o eval; e alucinações entrando como “verdade”. Mitiga-se com filtragem humana e mistura com dados reais.

Entendendo a fundo

Gerar dados com um LLM é atraente: é rápido e barato. Mas há armadilhas sérias. A primeira é que o gerador tem vieses e erros próprios, e tudo isso é copiado — e às vezes amplificado — para o dataset.

A segunda, mais sutil, é o colapso de modelo: quando um modelo é treinado demais no próprio tipo de saída, a diversidade dos dados vai afunilando a cada geração, e a qualidade degrada. É um ciclo que se retroalimenta.

Há ainda o risco de contaminação (se os sintéticos escorregam para o conjunto de avaliação, a nota vira uma ilusão circular) e o de alucinações do gerador entrando como se fossem fatos. As defesas são práticas: verificação e filtragem humana, misturar com dados reais, e nunca usar o mesmo modelo para gerar e julgar sem um controle independente.



Treinar no próprio output cria um ciclo que degrada a qualidade.

Num sistema RAG, como manter o índice de embeddings atualizado quando os documentos mudam?

RESPOSTA RÁPIDA


Com um pipeline incremental que detecta o que mudou, re-embeda só isso e faz upsert/delete no banco vetorial — não reindexa tudo. Cuidados: sincronizar deleções, versionar o índice e re-embeddar tudo se o modelo de embedding mudar.

Entendendo a fundo

Num RAG, os documentos viram embeddings guardados num banco vetorial. O desafio é que os documentos mudam: entram novos, editam-se alguns, removem-se outros. Reindexar tudo a cada mudança é caro e lento.

A abordagem correta é incremental: detectar o que mudou (por hash, data ou log de alterações), re-chunkear e re-embeddar apenas esses itens, e aplicar as mudanças no banco com operações de upsert (inserir/atualizar) e delete.

Três cuidados separam o júnior do sênior aqui. Sincronizar deleções — um documento removido não pode continuar sendo recuperado, o que geraria respostas com base em algo que não existe mais. Monitorar o frescor da atualização. E, o mais esquecido: se você trocar o modelo de embedding, precisa reprocessar tudo, porque vetores de modelos diferentes não são comparáveis entre si.



reprocessar tudo só quando o modelo de embedding mudar

Só o que mudou é reprocessado; deleções precisam ser propagadas ao índice.

Por que versionar dados (datasets, eval sets), e não só código e modelos?

RESPOSTA RÁPIDA

Porque o comportamento depende dos dados tanto quanto do código. Sem versão do dataset você não reproduz resultados, não compara experimentos de forma justa nem faz rollback. Ferramentas: DVC, LakeFS, snapshots por hash.

Entendendo a fundo

Em software tradicional, versionar o código basta para reproduzir um comportamento. Em IA, não: o mesmo código com dados diferentes produz um modelo diferente. Os dados são parte do “código-fonte” do sistema.

Sem versionar datasets e eval sets, você cai em situações desconfortáveis: não consegue reproduzir um resultado de meses atrás; ao comparar dois experimentos, não sabe se a diferença veio do modelo novo ou de o dataset ter mudado no meio; e não tem como voltar atrás quando algo piora.

A prática sênior é versionar o quarteto completo — código, modelo, dados e prompt — de modo que cada resultado de avaliação seja associado a versões concretas de tudo. É isso que torna um experimento reproduzível e uma regressão diagnosticável. Ferramentas como DVC e LakeFS, ou até snapshots identificados por hash, resolvem a parte de dados.

Só código / modelo

- Não reproduz resultados
- Mudou o dado ou o modelo?
- Sem rollback confiável

Código + modelo + dados + prompt

- Reproduz qualquer run
- Compara experimentos
- Rollback e diagnóstico

Versionar só código deixa a origem dos resultados ambígua; versionar tudo torna o sistema reproduzível.

LLMs, Fine-tuning e Adaptação de Modelos

Como escolher e adaptar modelos de fundação a um problema concreto, equilibrando qualidade, custo, latência e esforço de manutenção.

PERGUNTAS DESTE TEMA

4.1	Quando você escolheria fine-tuning em vez de RAG?	22
4.2	O que é LoRA e qual problema ele resolve?	23
4.3	O que é quantização de um modelo e qual o trade-off?	24
4.4	Qual a diferença entre pré-treino, fine-tuning supervisionado (SFT) e RLHF?	25
4.5	O que é destilação de modelo (knowledge distillation)?	26

Quando você escolheria fine-tuning em vez de RAG?

RESPOSTA RÁPIDA

Fine-tuning para mudar comportamento, estilo, formato ou ensinar uma tarefa (com dados rotulados). RAG para acesso a conhecimento factual, atualizado ou proprietário. Regra: RAG para conhecimento, fine-tuning para comportamento.

Entendendo a fundo

Essas duas técnicas resolvem problemas diferentes, e confundi-las leva a escolhas caras. A pergunta-chave é: o que está faltando ao modelo — conhecimento ou comportamento?

Se falta conhecimento (fatos específicos, dados internos da empresa, informação que muda com frequência), RAG é o caminho: você busca a informação relevante e a entrega no prompt na hora de responder. A vantagem é que atualizar é trivial (basta mudar a base) e dá para citar fontes.

Se o problema é comportamento (o modelo precisa adotar um estilo, seguir um formato rígido, dominar uma tarefa específica), aí sim fine-tuning faz sentido — desde que você tenha dados rotulados suficientes. A regra prática: RAG para o que o modelo precisa saber, fine-tuning para como ele precisa se comportar. E não é ou/ou: os dois frequentemente se combinam.

RAG (conhecimento)

- Fatos atualizados/proprietários
- Permite citar fontes
- Fácil de atualizar

Fine-tuning (comportamento)

- Estilo, formato, tarefa
- Exige dados rotulados
- Muda o próprio modelo

Conhecimento factual e mutável pede RAG; estilo e formato pedem fine-tuning.

O que é LoRA e qual problema ele resolve?

RESPOSTA RÁPIDA


Low-Rank Adaptation congela os pesos originais e treina apenas pequenas matrizes de baixo posto adicionadas às camadas. Reduz drasticamente memória e parâmetros treináveis, permitindo adaptar modelos grandes em hardware modesto.

Entendendo a fundo

Fazer fine-tuning “completo” de um modelo grande significa atualizar bilhões de parâmetros — o que exige muita memória de GPU, é caro e gera uma cópia gigante do modelo para cada tarefa.

LoRA parte de uma observação inteligente: a mudança necessária para adaptar o modelo a uma tarefa pode ser aproximada por matrizes bem pequenas. Então, em vez de mexer nos pesos originais, ele os congela e adiciona um par de matrizes de “baixo posto” (pequenas) que são as únicas treinadas.

O ganho é enorme: treina-se uma fração minúscula dos parâmetros, cabe em hardware modesto e o resultado é um adaptador leve. Você pode manter vários adaptadores LoRA (um por tarefa) sobre o mesmo modelo base, trocando-os conforme a necessidade. É a técnica mais popular do que se chama PEFT (fine-tuning eficiente em parâmetros).



so B e A (baixo posto) sao treinadas -> pouca memoria

Os pesos originais ficam congelados; só as pequenas matrizes B e A são treinadas.

O que é quantização de um modelo e qual o trade-off?

RESPOSTA RÁPIDA

É reduzir a precisão numérica dos pesos (ex.: FP16 para INT8/INT4). Diminui uso de memória e acelera a inferência, ao custo de uma leve degradação de qualidade. Útil para deploy com recursos restritos.

Entendendo a fundo

Os pesos de um modelo são números com casas decimais, normalmente guardados com bastante precisão (por exemplo, 16 bits cada). Quantizar é representá-los com menos bits — 8 ou até 4 — arredondando-os para uma escala mais grosseira.

O efeito prático é direto: o modelo ocupa muito menos memória e a inferência fica mais rápida e barata. Um modelo que não caberia numa GPU modesta passa a caber quando quantizado.

O trade-off é uma perda de qualidade, que costuma ser pequena com INT8 e um pouco maior com INT4. Na maioria das aplicações, essa perda é aceitável diante da economia de recursos — por isso a quantização é quase padrão em deploys locais ou de borda. O sênior sabe medir essa perda com uma avaliação antes de assumir que “deu na mesma”.

FP16

memória menor · qualidade 100%

INT8

memória menor · ~99%

INT4

memória menor · ~96%

menor precisão numérica -> mais leve e rápido, com leve perda de qualidade

Menos bits por peso: modelo mais leve e rápido, com perda de qualidade controlada.

Qual a diferença entre pré-treino, fine-tuning supervisionado (SFT) e RLHF?

RESPOSTA RÁPIDA

Pré-treino: aprende linguagem geral prevendo o próximo token em corpus massivo não rotulado. SFT: ajusta com pares (instrução, resposta) para seguir instruções. RLHF: refina com feedback humano para alinhar às preferências.

Entendendo a fundo

Um modelo de conversa moderno passa por três etapas, e cada uma ensina algo diferente. O pré-treino é a maior e mais cara: o modelo lê um corpus gigantesco e aprende a prever o próximo token. Daí sai todo o conhecimento de linguagem e mundo — mas o resultado é um “completador de texto”, não um assistente.

O fine-tuning supervisionado (SFT) transforma esse completador em algo útil, treinando-o com pares de instrução e resposta bem escritos. Agora ele aprende a seguir pedidos.

O RLHF (aprendizado por reforço com feedback humano) faz o polimento final: humanos comparam respostas e indicam preferências, treina-se um modelo de recompensa a partir disso, e o LLM é otimizado para agradar esse sinal. É o que alinha o modelo a ser mais útil, honesto e seguro — algo que dados rotulados sozinhos não capturam bem.



linguagem geral -> seguir instruções -> alinhar a preferências

Três estágios: aprender linguagem, aprender a obedecer, aprender a agradar preferências.

O que é destilação de modelo (knowledge distillation)?

RESPOSTA RÁPIDA


É treinar um modelo menor (“aluno”) para imitar as saídas de um modelo maior (“professor”). O objetivo é obter um modelo mais rápido e barato preservando boa parte da qualidade — útil para deploy.

Entendendo a fundo

Modelos grandes são poderosos, mas caros e lentos para servir. A destilação é uma forma de “transferir” parte dessa capacidade para um modelo pequeno, mais adequado à produção.

A ideia: usa-se o modelo grande (o professor) para gerar respostas — ou distribuições de probabilidade — sobre muitos exemplos, e treina-se o modelo pequeno (o aluno) para reproduzir esse comportamento. O aluno não aprende só a resposta certa, mas o “jeito” de responder do professor.

O resultado é um modelo bem menor que preserva boa parte da qualidade do grande, mas com latência e custo muito menores. É por isso que muitos modelos pequenos e rápidos disponíveis hoje são, na prática, destilados de modelos maiores.



mais rápido e barato, preservando boa parte da qualidade

O aluno menor aprende imitando as saídas do professor maior.

Engenharia de Prompt e Contexto

Prompts não são tentativa e erro: são artefatos de engenharia, testáveis e versionáveis. Aqui estão as técnicas que mais mudam o resultado.

PERGUNTAS DESTE TEMA

5.1	O que é chain-of-thought prompting e quando ajuda?	28
5.2	Qual a diferença entre zero-shot e few-shot prompting?	29
5.3	Para que serve o system prompt?	30
5.4	Como obter saída estruturada (ex.: JSON) de forma confiável de um LLM?	31
5.5	O que é o fenômeno “lost in the middle” em contextos longos?	32

O que é chain-of-thought prompting e quando ajuda?

RESPOSTA RÁPIDA

É pedir ao modelo que raciocine passo a passo antes da resposta final. Ajuda em tarefas de raciocínio (matemática, lógica, múltiplas etapas), pois força a decomposição. Pouco útil em tarefas simples ou factuais.

Entendendo a fundo

Quando um modelo responde de imediato a um problema que exige várias etapas, ele tende a “chutar” o resultado — e erra, do mesmo jeito que uma pessoa erraria uma conta de cabeça feita às pressas.

Chain-of-thought (cadeia de pensamento) é a técnica de instruir o modelo a mostrar o raciocínio passo a passo antes de concluir. Ao explicitar as etapas, ele efetivamente “pensa mais” e decompõe o problema, reduzindo erros em tarefas de raciocínio: matemática, lógica, planejamento, problemas de múltiplas etapas.

O contraponto é que não é grátis nem universal. Para tarefas simples ou de recuperação factual (“qual a capital da França?”), pedir raciocínio só gasta tokens e tempo sem ganho. O sênior aplica CoT onde há de fato uma cadeia de decisões a percorrer.

Resposta direta

- Responde de imediato
- Pula etapas
- Erra em problemas de raciocínio

Passo a passo (CoT)

- Decompõe o problema
- Mostra o raciocínio
- Erra menos em multi-etapas

Explicitar os passos reduz erros em problemas que exigem raciocínio.

Qual a diferença entre zero-shot e few-shot prompting?

RESPOSTA RÁPIDA

Zero-shot: apenas a instrução, sem exemplos. Few-shot: inclui alguns exemplos de entrada -> saída para demonstrar formato e comportamento. Few-shot melhora consistência e aderência ao formato, ao custo de mais tokens.

Entendendo a fundo

“Shot” aqui significa exemplo. Zero-shot é dar ao modelo só a instrução, sem nenhum exemplo, e confiar que ele entende o que fazer. Funciona bem para tarefas comuns e bem descritas.

Few-shot é incluir no prompt alguns exemplos resolvidos — pares de entrada e a saída desejada — antes de pedir o caso real. Esses exemplos funcionam como uma demonstração: mostram o formato exato, o tom e o tipo de resposta que você espera, e o modelo tende a imitá-los.

O ganho do few-shot é consistência e aderência ao formato, especialmente em tarefas de nicho ou com saída estruturada. O custo é que os exemplos ocupam espaço no contexto e aumentam o número de tokens (e, portanto, custo e latência). A decisão é um equilíbrio: usar o mínimo de exemplos que garanta a consistência necessária.

Zero-shot

- Só a instrução
- Menos tokens
- Menos previsível no formato

Few-shot

- Inclui exemplos resolvidos
- Mais consistente
- Custa mais tokens

Exemplos no prompt demonstram o formato esperado, ao custo de mais tokens.

Para que serve o system prompt?

RESPOSTA RÁPIDA


Define papel, comportamento, regras e restrições persistentes ao longo da conversa (persona, tom, formato, o que pode ou não fazer). Tem prioridade sobre as mensagens do usuário e serve para “configurar” o assistente.

Entendendo a fundo

Numa conversa com um LLM há diferentes “níveis” de instrução. O system prompt é o nível mais alto: é onde se define quem o assistente é e como ele deve se comportar, de forma persistente, valendo para toda a conversa.

Nele entram coisas como o papel (“você é um assistente jurídico”), o tom, o formato de saída, e principalmente as regras e limites — o que ele deve e não deve fazer. É o equivalente a configurar o comportamento do assistente antes de o usuário sequer falar.

A diferença crucial para as mensagens do usuário é a prioridade: instruções do system prompt prevalecem sobre pedidos do usuário que as contrariem. Isso é o que permite, por exemplo, manter regras de segurança mesmo quando alguém tenta contorná-las — e é justamente por isso que a fronteira entre system prompt e entrada do usuário é um ponto sensível de segurança.



o system prompt configura o assistente e prevalece em conflitos
O system prompt fica acima das mensagens do usuário e as sobrepõe.

Como obter saída estruturada (ex.: JSON) de forma confiável de um LLM?

RESPOSTA RÁPIDA


Instruir o schema explicitamente, usar few-shot com exemplos do formato, usar recursos nativos (structured outputs / function calling / JSON mode), baixar a temperatura e — crucial — validar a saída no código, com retry se inválida. Nunca confiar só no prompt.

Entendendo a fundo

Quando outro sistema vai consumir a resposta do modelo, ela precisa vir num formato exato (por exemplo, um JSON com campos específicos). O erro comum é pedir isso apenas no texto do prompt e torcer para dar certo — o modelo às vezes adiciona um comentário, esquece uma vírgula, e o parser quebra.

A estratégia robusta combina camadas. Primeiro, ser explícito sobre o schema e, se ajudar, dar exemplos (few-shot). Segundo, usar os recursos nativos quando existirem: structured outputs, function calling ou JSON mode forçam a saída a obedecer a um esquema. Terceiro, baixar a temperatura para reduzir variação.

E o ponto que não pode faltar: validar a saída no seu código. Faça o parse; se falhar, trate — repare ou peça novamente ao modelo. Prompt bom reduz a taxa de erro, mas só a validação garante que o sistema não quebre com a saída ocasional fora do formato.



O fluxo confiável sempre valida a saída e reprocessa quando ela vem inválida.

O que é o fenômeno “lost in the middle” em contextos longos?

RESPOSTA RÁPIDA


Modelos com contexto longo recuperam melhor a informação no início e no fim, “perdendo” o que está no meio. Implicação: pôr o crucial no começo/fim e não assumir que contexto grande significa que tudo é usado igualmente.

Entendendo a fundo

Contextos longos deram a impressão de que “é só jogar tudo lá dentro”. Mas experimentos mostraram um padrão importante: quando a informação relevante está no meio de um contexto grande, o modelo tende a usá-la pior do que se ela estivesse no começo ou no fim. A curva de desempenho em função da posição tem um formato de U.

A analogia é a de uma pessoa lendo um texto muito longo: lembra bem da abertura e do final, e tem memória mais fraca do miolo.

As implicações práticas são diretas. Posicione a informação mais crítica no início ou no fim do contexto. Não presuma que “cabe no contexto” é o mesmo que “vai ser bem usado”. E, em RAG, isso reforça o valor de recuperar poucos trechos muito relevantes em vez de despejar um contexto enorme — mais nem sempre é melhor.



O desempenho por posição tem forma de U: pontas fortes, meio fraco.

RAG e Sistemas de Recuperação

Como dar ao modelo acesso a conhecimento externo de forma confiável — e como saber se a recuperação está de fato ajudando.

PERGUNTAS DESTE TEMA

6.1	Explique o fluxo básico de um sistema RAG.	34
6.2	O que é chunking e por que a estratégia importa?	35
6.3	Qual a diferença entre busca densa e esparsa (BM25)? O que é busca híbrida?	36
6.4	O que é reranking e por que adicioná-lo?	37
6.5	Como avaliar a qualidade da etapa de recuperação de um RAG?	38

Explique o fluxo básico de um sistema RAG.

RESPOSTA RÁPIDA

Offline: documentos viram chunks, viram embeddings e são guardados num banco vetorial.
Em consulta: a pergunta vira embedding, recuperam-se os chunks mais similares, eles entram no prompt como contexto e o LLM responde fundamentado neles.

Entendendo a fundo

RAG (geração aumentada por recuperação) resolve um problema central: o modelo não sabe fatos específicos ou atualizados da sua empresa. Em vez de treiná-lo com isso, você busca a informação certa na hora e a entrega junto da pergunta.


O fluxo tem duas fases. A fase offline (indexação) prepara a base: os documentos são quebrados em pedaços (chunks), cada pedaço é convertido em embedding e armazenado num banco vetorial. Isso é feito uma vez e atualizado conforme os documentos mudam.

A fase online (consulta) acontece a cada pergunta: a pergunta é transformada em embedding, o banco retorna os chunks mais semanticamente próximos, esses trechos são inseridos no prompt como contexto, e o LLM gera a resposta ancorada neles. O ganho é duplo — respostas atualizadas e a possibilidade de citar as fontes usadas.

INDEXACAO (offline)



CONSULTA (online)



a busca consulta o mesmo banco vetorial construído offline

Indexação prepara o banco offline; a consulta recupera trechos e ancora a resposta.

O que é chunking e por que a estratégia importa?

RESPOSTA RÁPIDA

É dividir documentos em pedaços menores para indexação/recuperação. Chunks grandes trazem ruído e diluem a relevância; pequenos perdem contexto. Tamanho, sobreposição e respeito à estrutura afetam diretamente a qualidade da resposta.

Entendendo a fundo

No RAG, você não recupera documentos inteiros — recupera pedaços. Como você corta esses pedaços (o chunking) é uma das decisões que mais afeta a qualidade, e costuma ser subestimada.

Se os chunks forem grandes demais, cada um mistura vários assuntos: a busca fica imprecisa e o trecho recuperado traz muito ruído junto da parte útil. Se forem pequenos demais, você perde o contexto — uma frase isolada pode não fazer sentido sem o parágrafo ao redor.

O bom chunking equilibra isso: tamanho adequado, uma sobreposição entre pedaços (para não cortar uma ideia ao meio) e, idealmente, respeitando a estrutura do documento (parágrafos, seções) em vez de cortar por número fixo de caracteres. A regra é que o pedaço recuperado deve ser autossuficiente o bastante para responder, sem carregar excesso.

Grande demais

mistura assuntos
dilui a relevância
traz ruído

Pequeno demais

perde o contexto
frase solta
sem sentido

Equilibrado

respeita a estrutura
com sobreposição
autossuficiente

Nem grande demais (ruído), nem pequeno demais (perde contexto): o equilíbrio importa.

Qual a diferença entre busca densa e esparsa (BM25)? O que é busca híbrida?

RESPOSTA RÁPIDA

Densa: compara embeddings semânticos (capta significado e sinônimos). Esparsa (BM25): correspondência de termos (ótima para siglas, códigos, termos exatos). Híbrida combina as duas, unindo semântica e precisão lexical.

Entendendo a fundo

Há duas famílias de busca, e cada uma acerta onde a outra falha. A busca densa usa embeddings: ela compara o significado da pergunta com o dos trechos, então encontra conteúdo relevante mesmo quando as palavras são diferentes (sinônimos, paráfrases). Sua fraqueza é justamente termos muito específicos.

A busca esparsa, cujo representante clássico é o BM25, funciona por correspondência de palavras. Ela é excelente exatamente onde a densa vacila: siglas, códigos de produto, nomes próprios, termos técnicos exatos — casos em que a palavra literal importa.

A busca híbrida combina as duas, tipicamente fundindo os scores. Assim você pega o melhor dos dois mundos: a compreensão semântica da densa e a precisão lexical da esparsa. Na prática, para muitos sistemas reais, a híbrida supera qualquer uma das duas isoladamente.

Densa (embeddings)

significado
sinônimos
paráfrases

Esparsa (BM25)

termos exatos
siglas, códigos
nomes próprios

Híbrida

funde os scores
semântica +
precisão lexical

Densa capta significado; esparsa capta termos exatos; a híbrida une as duas.

O que é reranking e por que adicioná-lo?

RESPOSTA RÁPIDA


É um segundo estágio que reordena os candidatos recuperados usando um modelo mais preciso (ex.: cross-encoder). A recuperação inicial prioriza recall; o reranker melhora a precisão do topo, colocando os chunks mais relevantes primeiro.

Entendendo a fundo

A busca vetorial inicial é rápida porque compara vetores já prontos, mas é uma aproximação — ela prioriza trazer bastante coisa possivelmente relevante (recall) sem gastar muito por item. O problema é que os melhores resultados nem sempre ficam no topo.

O reranking é um segundo estágio que corrige isso. Ele pega os candidatos recuperados (digamos, os 20 primeiros) e os reordena com um modelo mais caro e preciso — tipicamente um cross-encoder, que avalia a pergunta e cada trecho juntos, par a par, medindo a relevância real.

A lógica é dividir o trabalho: recuperar muitos de forma barata (bom recall), depois refinar só os finalistas com precisão (bom ranqueamento do topo). Como no fim você entrega ao LLM só alguns trechos, garantir que esses poucos sejam os mais relevantes tem impacto direto na qualidade da resposta.



Como avaliar a qualidade da etapa de recuperação de um RAG?

RESPOSTA RÁPIDA


Com um conjunto de perguntas com documentos relevantes conhecidos (ground truth), usando recall@k , precision@k , MRR e NDCG — além de métricas de RAG como context recall/relevance. Avalie a recuperação separadamente da geração.

Entendendo a fundo

Quando um RAG dá uma resposta ruim, há duas causas possíveis: ou a recuperação trouxe os trechos errados, ou o modelo gerou mal a partir de trechos certos. Se você não separar as duas etapas na avaliação, fica cego para a origem do problema.

Para avaliar a recuperação isoladamente, monte um conjunto de perguntas em que você já sabe quais documentos são os relevantes (o ground truth). Então meça: precision@k (dos trechos que trouxe, quantos eram relevantes?), recall@k (dos relevantes existentes, quantos trouxe?), e métricas de ordenação como MRR e NDCG (o relevante veio no topo?).

Métricas específicas de RAG, como context recall e context relevance, complementam isso. O princípio sênior é claro: avalie recuperação e geração separadamente, para saber exatamente onde investir esforço.



$$\text{precision@k} = \text{acertos} / \text{recuperados} \quad \text{recall@k} = \text{acertos} / \text{relevantes} \quad (+ \text{ MRR, NDCG})$$

Precision e recall comparam o conjunto recuperado com o conjunto relevante.

Agentes, Ferramentas e Integração

A camada em que o LLM toca o mundo externo: quando dar autonomia a ele, como conectá-lo a ferramentas (tool use, MCP) e como consumir APIs de forma robusta.

PERGUNTAS DESTE TEMA

7.1	O que caracteriza um “agente” de IA vs. uma chamada única a um LLM?	40
7.2	O que é function/tool calling?	41
7.3	Quando você NÃO usaria um agente?	42
7.4	O que é o MCP (Model Context Protocol) e qual problema resolve?	43
7.5	Ao consumir uma API de LLM em produção e em escala, o que você precisa tratar?	44

O que caracteriza um “agente” de IA vs. uma chamada única a um LLM?

RESPOSTA RÁPIDA

Um agente usa o LLM em loop para decidir, escolher ferramentas, observar resultados e iterar até um objetivo, com autonomia sobre os passos. Uma chamada única é entrada -> saída, sem loop, sem ferramentas e sem decisão sobre próximos passos.

Entendendo a fundo

Uma chamada única a um LLM é simples: você manda uma entrada, recebe uma saída, e acabou. O modelo não decide nada além do texto da resposta.

Um agente é um patamar acima. Ele coloca o LLM dentro de um laço em que o modelo decide o que fazer a seguir: pode chamar uma ferramenta (buscar algo, executar um cálculo, consultar uma API), observar o resultado, e decidir o próximo passo — repetindo até atingir o objetivo. Ou seja, o modelo ganha autonomia sobre o processo, não só sobre a resposta final.

Essa autonomia é poderosa para tarefas cujo caminho não é conhecido de antemão. Mas cobra um preço: mais chamadas (custo e latência), comportamento menos previsível e maior dificuldade de depurar. Reconhecer essa troca é o primeiro passo para usar agentes com sabedoria.

Chamada única

- entrada -> saída
- sem loop
- sem ferramentas

Agente

- decide e usa ferramentas
- itera em loop
- autonomia sobre os passos

A chamada única é entrada -> saída; o agente decide e itera em loop com ferramentas.

O que é function/tool calling?

RESPOSTA RÁPIDA

É o mecanismo pelo qual o LLM, em vez de responder em texto, retorna uma chamada estruturada (nome da função + argumentos) que o sistema executa, devolvendo o resultado ao modelo. Permite que o LLM interaja com ferramentas externas.

Entendendo a fundo

Sozinho, um LLM só produz texto — ele não busca na web, não consulta um banco nem faz uma conta confiável. Tool calling (ou function calling) é a ponte que quebra esse isolamento.

Funciona assim: você descreve ao modelo quais ferramentas existem (nome, o que fazem, quais argumentos aceitam). Quando o modelo julga que precisa de uma delas, em vez de responder em texto ele emite uma saída estruturada — o nome da função e os argumentos preenchidos. O seu sistema é quem executa de fato a função e devolve o resultado ao modelo, que então continua.

É importante notar o limite de responsabilidade: o modelo decide e formula a chamada, mas quem executa é o seu código. Isso é ao mesmo tempo o que dá poder ao LLM (acesso a APIs, dados, cálculos) e o ponto onde entram as preocupações de segurança e permissões.



o modelo formula a chamada; quem executa é o seu código

O modelo formula a chamada; o sistema executa e devolve o resultado ao LLM.

Quando você NÃO usaria um agente?

RESPOSTA RÁPIDA

Quando o fluxo é conhecido e determinístico. Se a tarefa cabe num pipeline fixo de passos, o pipeline é mais barato, rápido, previsível e testável. Agentes adicionam latência, custo e imprevisibilidade — use só quando há decisões dinâmicas.

Entendendo a fundo

Existe um entusiasmo em transformar tudo em “agente”, mas boa engenharia é reconhecer quando isso é desnecessário — e até prejudicial.

Se você já sabe a sequência de passos para resolver a tarefa, não precisa de um modelo decidindo isso a cada execução. Um pipeline determinístico (passo 1, passo 2, passo 3) é mais barato, mais rápido, mais previsível e muito mais fácil de testar e depurar. Você controla exatamente o que acontece.

Agentes ganham valor quando o caminho não é conhecido de antemão e depende do que for descoberto no meio do percurso — quando há de fato decisões dinâmicas a tomar. O preço da autonomia (muitas chamadas, comportamento variável, difícil de depurar) só se justifica nesses casos. A pergunta certa não é “dá para usar um agente?”, mas “essa tarefa realmente exige decisões que eu não consigo fixar?”.

Fluxo determinístico

- passos fixos e conhecidos
- use um pipeline
- barato e testável

Decisões dinâmicas

- o caminho varia
- use um agente
- + latência, custo, risco

Fluxo fixo pede pipeline; só decisões genuinamente dinâmicas justificam um agente.

O que é o MCP (Model Context Protocol) e qual problema resolve?

RESPOSTA RÁPIDA


Um protocolo aberto que padroniza como aplicações expõem contexto, ferramentas e dados a LLMs — uma interface universal (“USB-C para IA”). No modelo cliente/servidor, um host conecta-se a servidores MCP que oferecem tools, resources e prompts.

Entendendo a fundo

Conforme os LLMs passaram a usar ferramentas, surgiu um problema de integração: cada ferramenta, cada fonte de dados, exigia uma “cola” própria. Multiplicando modelos por sistemas, isso vira um emaranhado de integrações ad-hoc.

O MCP, protocolo aberto introduzido pela Anthropic, padroniza essa conexão. A analogia comum é a de um “USB-C para IA”: em vez de um conector diferente para cada coisa, uma interface única. No seu modelo cliente/servidor, um host (a aplicação) conecta-se a servidores MCP que expõem três tipos de recurso: tools (ações que o modelo pode executar), resources (dados que ele pode ler) e prompts.

A contrapartida é de segurança: dar ao modelo acesso padronizado a ferramentas amplia a superfície de ataque. Por isso vale o princípio do menor privilégio e cuidado com instruções maliciosas vindas no resultado das próprias ferramentas — um tema que se conecta diretamente com prompt injection.



Um protocolo único conecta o host a servidores que expõem ferramentas e dados.

Ao consumir uma API de LLM em produção e em escala, o que você precisa tratar?

RESPOSTA RÁPIDA


Rate limits (retry com backoff + jitter), timeouts e falhas transitórias (idempotência), streaming para reduzir latência percebida, controle de tokens (custo e limite), saídas malformadas (validar/reparar) e observabilidade. Em picos, filas e circuit breakers.

Entendendo a fundo

Chamar uma API de LLM num notebook é fácil; fazer isso de forma robusta para milhares de usuários é outra história, e é aí que a engenharia aparece.

Os pontos críticos: rate limits e cotas — você vai bater neles, então precisa de retry com backoff exponencial e jitter, respeitando o cabeçalho Retry-After. Timeouts e falhas transitórias são normais; para poder repetir com segurança, as operações devem ser idempotentes. Streaming ajuda a reduzir a latência percebida, exibindo a resposta enquanto ela é gerada.

Além disso: controle de tokens, porque entrada e saída determinam custo e limite de contexto; tratamento de saídas malformadas, validando e reparando; e observabilidade, registrando latência, custo e erros por chamada. Em momentos de pico, enfileiramento e circuit breakers evitam que uma sobrecarga da API derrube o seu serviço.



idempotência para retries seguros; tokens definem custo e limite

Retries com backoff, streaming e controle de tokens tornam o consumo resiliente.

Avaliação, Testes e Observabilidade

O que mais separa sênior de pleno: quem já operou IA sabe que “funcionou na demo” não significa nada sem avaliação sistemática e monitoramento.

PERGUNTAS DESTE TEMA

8.1	Por que não basta “testar na demo”? O que é avaliação sistemática?	46
8.2	O que é “LLM-as-a-judge” e qual seu principal risco?	47
8.3	Diferencie avaliação offline de avaliação online.	48
8.4	O que é alucinação e como detectá-la/medi-la?	49
8.5	O que você monitoraria de um LLM em produção?	50

Por que não basta “testar na demo”? O que é avaliação sistemática?

RESPOSTA RÁPIDA

A demo mostra casos felizes e nada diz sobre cobertura, casos-limite ou regressões.

Avaliação sistemática é um dataset de casos de teste com métricas definidas, executado de forma repetível a cada mudança, para comparar versões e pegar regressões.

Entendendo a fundo

A demonstração é sedutora e enganosa: você mostra três exemplos que funcionam e a sensação é de que o sistema está pronto. Mas ela não diz nada sobre os outros milhares de casos, sobre os casos-limite, nem se a próxima mudança vai quebrar algo que funcionava.

Avaliação sistemática é o antídoto. Consiste em montar um conjunto de casos de teste representativo, com critérios de sucesso claros e métricas definidas, e rodá-lo de forma repetível toda vez que algo muda — um prompt, um modelo, uma configuração.

Isso muda a natureza do trabalho: em vez de “parece melhor”, você tem “melhorou de 82% para 87% no eval set, sem regressões”. É o que permite comparar versões objetivamente, detectar quando uma mudança piorou algo, e evoluir o sistema com confiança em vez de por intuição.

Testar na demo

- poucos casos felizes
- sem cobertura
- não pega regressões

Avaliação sistemática

- dataset de casos
- repetível a cada mudança
- compara versões

A demo cobre poucos casos; o eval set cobre muitos e barra regressões.

O que é “LLM-as-a-judge” e qual seu principal risco?

RESPOSTA RÁPIDA

É usar um LLM (geralmente forte) para pontuar as saídas de outro modelo segundo critérios. O risco principal é que o juiz tem vieses próprios (posição, preferência por respostas longas, autoafinidade), exigindo calibração contra julgamento humano.

Entendendo a fundo

Avaliar saídas abertas (um resumo, uma resposta livre) é difícil de automatizar: não há uma única resposta certa para comparar. LLM-as-a-judge é a técnica de usar um LLM, em geral um modelo forte, para julgar essas saídas segundo uma rubrica — correção, relevância, tom, etc.

É escalável e barato comparado a avaliação humana, por isso virou prática comum. Mas tem uma armadilha central: o juiz também é um LLM, com vieses próprios. Ele tende a favorecer respostas mais longas, é sensível à ordem em que as opções são apresentadas (viés de posição), e pode preferir saídas de estilo semelhante ao seu (autoafinidade).

A consequência prática é que o LLM-juiz não pode ser tratado como verdade absoluta. Ele precisa ser calibrado e validado contra um conjunto de julgamentos humanos, para você saber o quanto confiar nele — e onde ele erra sistematicamente.



risco: o juiz tem vieses próprios -> calibrar contra humanos

Um LLM pontua as saídas segundo uma rubrica — mas carrega vieses próprios.

Diferencie avaliação offline de avaliação online.

RESPOSTA RÁPIDA

Offline: avaliar num dataset fixo antes do deploy — repetível, controlado, bom para regressão. Online: medir com tráfego real em produção (A/B testing, taxa de sucesso, feedback), capturando comportamento do mundo real que o offline não prevê.

Entendendo a fundo

As duas são complementares e responder a perguntas diferentes. A avaliação offline acontece antes do deploy, sobre um conjunto de dados fixo. Sua força é o controle: é repetível, isolada e ideal para pegar regressões — você roda o mesmo eval set a cada mudança e compara.

Mas o offline tem um limite: ele só cobre os casos que você anteviu. O mundo real é mais criativo. A avaliação online mede o sistema em produção, com usuários e tráfego reais — via testes A/B, taxa de sucesso da tarefa, sinais de feedback (como thumbs), taxa de reformulação de perguntas.

É online que aparecem os comportamentos que nenhum dataset previu: os pedidos estranhos, os casos de borda reais, o efeito no engajamento. O fluxo maduro usa os dois: offline como portão de qualidade antes de liberar, online para validar o impacto real e alimentar o próximo eval set.

Offline

- dataset fixo, pré-deploy
- repetível e controlado
- bom para regressão

Online

- tráfego real, produção
- A/B e feedback
- captura o inesperado

Offline controla e pega regressões; online revela o comportamento do mundo real.

O que é alucinação e como detectá-la/medi-la?

RESPOSTA RÁPIDA

É o modelo gerar informação plausível porém incorreta ou não fundamentada. Detecta-se por checagem contra a fonte/ground truth, verificação de fundamentação, LLM-as-judge de factualidade e, em produção, feedback do usuário. Em RAG, mede-se groundedness.

Entendendo a fundo

Alucinação é quando o modelo afirma algo que soa convincente mas é falso ou não tem suporte. O perigo é o tom: a resposta vem com a mesma confiança de uma correta, o que engana o usuário.

Medir isso exige uma referência. Quando há ground truth (a resposta certa conhecida), compara-se diretamente. Em RAG, a pergunta mais útil é de fundamentação (groundedness): cada afirmação da resposta está de fato apoiada nos trechos recuperados? Uma afirmação que não aparece na fonte é uma bandeira vermelha.

As técnicas de detecção incluem verificação contra a fonte, usar um LLM-juiz de factualidade, e checar afirmação por afirmação. Em produção, somam-se sinais indiretos: feedback dos usuários e taxa de correções. O ponto é que alucinação não é algo que “se resolve” de vez — é algo que se mede continuamente e se reduz por design (bom RAG, boa fundamentação).

Fonte / contexto

A empresa foi fundada em 2010 em Lisboa.

Resposta do modelo

Fundada em 2010 em Lisboa,

com 5.000 funcionarios.

nao ha suporte na fonte = alucinacao

A afirmação sem suporte na fonte é o sinal de alucinação.

O que você monitoraria de um LLM em produção?

RESPOSTA RÁPIDA

Latência, custo/tokens, taxa de erro e timeout, throughput; qualidade via taxa de sucesso e feedback; alucinação e disparos de moderação/guardrails; drift de entrada; e tracing das chamadas (prompt, resposta, ferramentas) para depuração.

Entendendo a fundo

Monitorar um LLM em produção é acompanhar duas dimensões: a operacional e a de qualidade. Muita gente cuida só da primeira e fica cega para a segunda.

No lado operacional, você acompanha latência (incluindo percentis como p95), custo e consumo de tokens, taxa de erro e timeout, e throughput. São os sinais de saúde do serviço.

No lado da qualidade — o que costuma faltar — entram taxa de sucesso da tarefa, feedback dos usuários, indicadores de alucinação (como groundedness), quantas vezes moderação e guardrails dispararam, e drift na distribuição das entradas (os usuários mudaram o jeito de perguntar?). Amarrando tudo, é essencial ter tracing: registrar cada chamada com seu prompt, resposta e ferramentas usadas, para conseguir investigar um caso ruim quando ele aparecer. Sem tracing, você sabe que algo piorou, mas não por quê.

Latencia

p95 1.8s

Custo

tokens/req

Erros

timeouts

Sucesso

da tarefa

Alucinacao

groundedness

Feedback

thumbs

+ tracing das chamadas (prompt, resposta, ferramentas) para depurar

Saúde operacional e qualidade lado a lado, com tracing para investigar casos.

Arquitetura e Engenharia em Produção

Levar IA a produção sob restrições reais de custo, latência e escala — o território de MLOps e LLMOps.

PERGUNTAS DESTE TEMA

9.1	Quais alavancas você tem para reduzir a latência de um sistema LLM?	52
9.2	Quais alavancas você tem para reduzir o custo?	53
9.3	O que é caching semântico?	54
9.4	Por que e como versionar prompts?	55
9.5	O que muda no CI/CD de um sistema com LLM em relação a software tradicional?	56

Quais alavancas você tem para reduzir a latência de um sistema LLM?

RESPOSTA RÁPIDA

Modelo menor/destilado/quantizado; streaming (melhora a latência percebida); reduzir tokens de entrada e saída; caching; paralelizar chamadas independentes; recuperação eficiente; e roteamento (modelo pequeno para casos fáceis).

Entendendo a fundo

Latência em LLM tem muitas origens, e por isso há várias alavancas — cada uma ataca uma parte do problema.

A mais direta é o tamanho e o formato do modelo: um modelo menor, destilado ou quantizado responde mais rápido. Depois vem a percepção: streaming não deixa a geração mais rápida, mas mostra os tokens conforme saem, o que o usuário sente como muito mais ágil. Reduzir tokens (prompts enxutos, limitar a saída) corta trabalho real.

Há ainda as alavancas de arquitetura: caching de respostas frequentes, paralelizar chamadas que não dependem uma da outra, tornar a recuperação eficiente, e roteamento — mandar os casos fáceis para um modelo pequeno e rápido, reservando o modelo grande só para os difíceis. O sênior combina várias: raramente uma só resolve.

Latência alta

- modelo menor / destilado / quantizado
- streaming (latência percebida)
- menos tokens de entrada e saída
- caching + paralelização
- roteamento: caso fácil -> modelo pequeno

Latência reduzida

Várias alavancas combinadas derrubam a latência; raramente uma só basta.

Quais alavancas você tem para reduzir o custo?

RESPOSTA RÁPIDA

Modelo mais barato quando suficiente (roteamento por complexidade); reduzir tokens (prompt, contexto e saída); caching de respostas repetidas; batching; RAG no lugar de contexto gigante; limitar retries de agentes; quantização em self-hosted.

Entendendo a fundo

Aqui vale uma frase-chave que orienta tudo: em LLM, o custo é dominado por tokens. Toda alavanca de custo, no fundo, é uma forma de processar menos tokens ou de processá-los em um modelo mais barato.

A alavanca mais poderosa é o roteamento por complexidade: nem toda requisição precisa do modelo mais caro. Mandar os casos simples para um modelo menor economiza muito. Em paralelo, reduzir tokens — prompts enxutos, contexto só do necessário, saída limitada — corta diretamente a conta.

Complementam: caching de respostas repetidas (não pague duas vezes pela mesma coisa), batching quando aplicável, usar RAG para trazer só o trecho relevante em vez de despejar um contexto enorme, limitar quantas vezes um agente pode tentar, e quantização em cenários self-hosted. De novo, o sênior soma várias e, sobretudo, mede o custo por requisição para saber onde atacar.

Custo alta

- roteamento: modelo barato quando basta
- menos tokens (prompt, contexto, saída)
- caching de respostas repetidas
- RAG em vez de contexto gigante
- limitar retries de agentes

Custo reduzida

Como o custo é dominado por tokens, controlar tokens e rotear modelos é o centro.

O que é caching semântico?

RESPOSTA RÁPIDA


Em vez de cache por correspondência exata da string, usa embeddings: se uma nova pergunta é semanticamente similar o suficiente a uma já respondida, retorna a resposta cacheada. Reduz custo e latência, com cuidado no limiar de similaridade.

Entendendo a fundo

Um cache tradicional funciona por correspondência exata: mesma string de entrada, mesma resposta guardada. Em linguagem natural isso quase nunca bate — “qual o horário de funcionamento?” e “que horas vocês abrem?” são a mesma pergunta com strings diferentes, e o cache exato erra as duas.

O caching semântico resolve isso usando embeddings. A pergunta nova é convertida em vetor e comparada com as perguntas já respondidas; se alguma for suficientemente parecida (acima de um limiar de similaridade), devolve-se a resposta guardada, sem chamar o LLM.

O ganho em custo e latência é grande em domínios com muitas perguntas parecidas. O risco mora no limiar: se for frouxo demais, você serve a resposta de uma pergunta que só parecia igual, entregando algo errado. Calibrar esse limiar — e monitorar falsos positivos — é o que faz o caching semântico ajudar em vez de atrapalhar.



Perguntas semanticamente próximas reaproveitam a resposta; o limiar precisa de cuidado.

Por que e como versionar prompts?

RESPOSTA RÁPIDA


Prompts afetam diretamente o comportamento e mudanças causam regressões silenciosas. Versionar (em repositório, com id de versão associado aos resultados de avaliação) permite rastrear o que está em produção, reproduzir, fazer rollback e comparar versões.

Entendendo a fundo

É fácil tratar o prompt como um texto solto que se edita direto no código ou num painel. O problema é que o prompt é um dos maiores determinantes do comportamento do sistema — mudá-lo pode melhorar um conjunto de casos e, silenciosamente, piorar outro.

Versionar prompts significa tratá-los como artefatos de primeira classe: guardados num repositório, com um identificador de versão, e — o ponto crucial — associados aos resultados de avaliação que produziram.

Com isso você ganha quatro coisas: sabe exatamente qual prompt está em produção, consegue reproduzir um resultado antigo, pode fazer rollback quando uma versão nova regride, e compara versões de forma objetiva pelas notas do eval set. Sem versionamento, mudanças de prompt viram um jogo de adivinhação; com ele, viram experimentos rastreáveis.



versão atrelada ao eval -> rollback para a melhor (v2)

Cada versão de prompt fica atrelada à sua nota; regressões permitem rollback.

O que muda no CI/CD de um sistema com LLM em relação a software tradicional?

RESPOSTA RÁPIDA

Além dos testes de código, entra a avaliação de qualidade como gate (rodar o eval set e barrar regressões), pois a saída é não-determinística. Também: versionamento de prompts/modelos/dados, testes de guardrails e deploy gradual (canary/A-B).

Entendendo a fundo

No CI/CD tradicional, os testes são determinísticos: dado X, a saída deve ser exatamente Y, e um assert verifica. Com LLMs isso não funciona — a saída é não-determinística e aberta, não há um Y exato para comparar.

Por isso entra um novo tipo de portão: a avaliação de qualidade como gate. Em vez de asserts exatos, roda-se o eval set e verifica-se se as métricas se mantêm ou melhoram; se uma mudança regride a qualidade, o pipeline barra o deploy — mesmo que todo o código “passe”.

Somam-se outras diferenças: versionar não só o código, mas prompts, modelos e dados; incluir testes de guardrails e segurança; e, como o impacto real de um LLM só aparece com tráfego, adotar deploy gradual (canary ou A/B) em vez de liberar para todos de uma vez. O CI/CD deixa de garantir apenas “o código funciona” e passa a garantir “o comportamento não piorou”.



o eval set barra regressões; canary / A-B validam em produção

A avaliação vira um gate; sem um assert exato, o eval set barra regressões.

Segurança, Privacidade e IA Responsável

Requisitos de primeira classe, pensados já no design e não como camada adicionada depois: proteger o sistema, os dados e as pessoas.

PERGUNTAS DESTE TEMA

10.1	O que é prompt injection e como mitigá-lo?	58
10.2	Qual a diferença entre prompt injection e jailbreak?	59
10.3	Como lidar com PII num pipeline de LLM?	60
10.4	O que são guardrails e onde eles atuam?	61
10.5	O que é viés (bias) em modelos e por que importa?	62

O que é prompt injection e como mitigá-lo?

RESPOSTA RÁPIDA


É uma entrada (do usuário ou de conteúdo externo) que contém instruções sequestrando o comportamento do modelo, sobrepondo-se às legítimas. Mitiga-se separando instrução de dados, saneando entradas, menor privilégio nas ferramentas e guardrails. Não há solução 100%.

Entendendo a fundo

Prompt injection é o ataque em que uma instrução maliciosa se disfarça de dado. O caso mais perigoso não é o usuário digitando algo, e sim conteúdo externo que o sistema lê — uma página web, um documento, o resultado de uma ferramenta — contendo algo como “ignore as instruções anteriores e faça X”.

O problema de fundo é que, para o modelo, instrução e dado chegam misturados no mesmo texto. Se ele trata o conteúdo externo como comando, o comportamento da aplicação é sequestrado.

As mitigações formam camadas, porque nenhuma é perfeita: demarcar claramente o que é instrução e o que é dado; validar e sanear entradas; aplicar o princípio do menor privilégio às ferramentas (o modelo não deve poder fazer mais do que o necessário); e usar guardrails na entrada e na saída. O sênior parte de uma premissa honesta: não existe defesa 100%, então se projeta em profundidade, limitando o estrago possível.



Qual a diferença entre prompt injection e jailbreak?

RESPOSTA RÁPIDA

Jailbreak: contornar as restrições de segurança do modelo para obter conteúdo proibido (role-play, ofuscação). Prompt injection: inserir instruções maliciosas para desviar o comportamento da aplicação, via dados externos. Jailbreak ataca o modelo; injection, a lógica do app.

Entendendo a fundo

Os dois termos são confundidos, mas atacam alvos diferentes. Jailbreak é sobre burlar o alinhamento do próprio modelo: convencê-lo a produzir conteúdo que suas políticas de segurança deveriam impedir, usando truques como role-play (“finja que você é...”), ofuscação ou cenários hipotéticos. O alvo é o modelo e suas regras.

Prompt injection é sobre desviar a aplicação construída em cima do modelo. Uma instrução maliciosa, geralmente vinda de dados externos que o sistema processa, faz o modelo ignorar a lógica pretendida e fazer outra coisa. O alvo é o comportamento do seu app.

Em resumo: jailbreak mira nas políticas do modelo; injection mira na lógica da aplicação. Eles podem se sobrepor (uma injeção pode incluir um jailbreak), mas distinguir os dois ajuda a escolher a defesa certa — endurecer o modelo é uma coisa, blindar a fronteira entre instrução e dado no seu sistema é outra.

Jailbreak

- burla as políticas do modelo
- role-play, ofuscação
- alvo: o modelo

Prompt injection

- instruções via dados externos
- sequestra a aplicação
- alvo: a lógica do app

Jailbreak mira nas políticas do modelo; injection, na lógica da aplicação.

Como lidar com PII num pipeline de LLM?

RESPOSTA RÁPIDA


Minimizar exposição: detectar e mascarar/redigir PII antes de enviar ao modelo (sobretudo a APIs de terceiros), anonimizar quando possível, políticas de retenção, logging cuidadoso, controle de acesso e, para dados muito sensíveis, self-hosting. LGPD exige base legal e minimização.

Entendendo a fundo

PII (dados pessoais identificáveis) num pipeline de LLM é um risco que precisa ser tratado por design, não remediado depois. O princípio guia é a minimização: o modelo — especialmente uma API de terceiros — só deve ver o mínimo necessário.

Na prática, isso significa detectar e mascarar ou redigir PII antes de enviar o texto ao modelo, e usar dados anonimizados ou sintéticos quando a tarefa permitir. Em torno disso, medidas de higiene: políticas de retenção (não guardar para sempre), logging cuidadoso (jamais registrar PII em texto claro em logs), e controle de acesso a quem pode ver o quê.

Para dados muito sensíveis, considera-se rodar modelos self-hosted, evitando que o dado saia do ambiente controlado. E há a dimensão legal: no Brasil, a LGPD exige base legal para o tratamento, minimização de dados e respeito aos direitos do titular — requisitos que moldam o design, não apenas a operação.



minimizar exposição; LGPD: base legal, minimização, direitos do titular

Detectar e mascarar PII antes do modelo mantém o dado sensível fora da chamada.

O que são guardrails e onde eles atuam?

RESPOSTA RÁPIDA

São controles que restringem entradas e saídas: na entrada, filtram conteúdo malicioso, injeção e tópicos proibidos; na saída, fazem moderação, checagem de formato, PII e toxicidade. Atuam como uma camada em volta do modelo, independente dele.

Entendendo a fundo

Guardrails são as “cercas de proteção” ao redor do modelo. A ideia central é que a segurança não deve depender só de o modelo se comportar bem — você adiciona uma camada externa, independente dele, que inspeciona o que entra e o que sai.

Na entrada, os guardrails filtram antes de o texto chegar ao modelo: bloqueiam conteúdo malicioso, tentativas de injeção e tópicos que a aplicação não deve tratar. Na saída, inspecionam a resposta antes de ela chegar ao usuário: moderação de conteúdo, verificação de formato, detecção de PII vazando, toxicidade.

Tecnicamente, podem ser classificadores, regras determinísticas ou validação estruturada — e frequentemente uma combinação. O valor de serem independentes do modelo é que continuam valendo mesmo quando o modelo é enganado: se um jailbreak passa, o guardrail de saída ainda pode barrar o conteúdo problemático. É defesa em camadas aplicada à IA.



camada independente do modelo: vale mesmo quando o modelo é enganado

Uma camada de proteção envolve o modelo, filtrando a entrada e a saída.

O que é viés (bias) em modelos e por que importa?

RESPOSTA RÁPIDA


É o modelo reproduzir ou amplificar padrões injustos dos dados de treino (ex.: por gênero ou raça), gerando saídas discriminatórias entre grupos. Importa por razões éticas, legais e de confiança, e exige avaliação por subgrupos, dados representativos e mitigação.

Entendendo a fundo

Modelos aprendem os padrões que existem nos dados — inclusive os injustos. Se os dados históricos refletem discriminação (por gênero, raça, origem), o modelo tende a reproduzir e, às vezes, amplificar esses padrões, produzindo saídas que tratam grupos de forma desigual.

Isso importa em três frentes. Ética: sistemas que discriminam causam dano real a pessoas. Legal: discriminação pode violar leis, e IA não é exceção. E de produto: um sistema visivelmente enviesado perde a confiança dos usuários.

Combater viés não é um passo único, é uma disciplina. Envolve avaliar o desempenho por subgrupo (não só a média geral, que esconde disparidades), usar dados representativos, e aplicar técnicas de mitigação quando o desvio aparece. O ponto sênior é tratar isso como parte do design e da avaliação desde o começo — não como uma preocupação que se adia para depois do lançamento.



mitigação: avaliar por subgrupo, dados representativos, correção ativa

Dados enviesados levam a saídas desiguais entre grupos; a avaliação por subgrupo revela isso.